

미션 15 Docker 기반 협업 워크플로우 보고서

4팀 김도민

1. Docker Hub URL

<https://hub.docker.com/r/ming2tofu33/mission15-researcher1>

2. 전체 아키텍처

연구자 1 Docker 이미지 train_model.py train.csv, test.csv 포함	공유 볼륨 ./shared:/shared model.pkl, test.csv, metrics.json	연구자 2 Jupyter 이미지 inference.ipynb result.csv 생성
학습 실행 RMSE 계산 model.pkl 저장	파일 전달 통로 컨테이너와 호스트 공유	모델 로드 test.csv 예측 result.csv 저장

docker-compose.yml은 연구자 1 컨테이너와 연구자 2 Jupyter 컨테이너가 같은 shared 디렉터리를 바라보도록 구성한다. 연구자 1은 학습 후 /shared/model.pkl과 /shared/test.csv를 생성하고, 연구자 2는 해당 파일을 읽어 /shared/result.csv를 저장한다.

3. 제출 코드 구조

경로	역할
researcher1/train_model.py	전처리, 모델 학습, RMSE 평가, model.pkl 저장
researcher1/Dockerfile	연구자 1 학습 자동화 이미지 정의
researcher2/inference.py	저장된 모델과 test.csv를 이용한 추론
researcher2/inference.ipynb	연구자 2 추론 과정 기록
shared/	model.pkl, test.csv, metrics.json, result.csv 공유

4. 연구자 1 데이터 전처리 및 모델링 결과

train.csv 7000행을 사용해 학생 성취도 지표 Performance Index를 예측하는 회귀 모델을 학습했다. 입력 변수는 Hours Studied, Previous Scores, Extracurricular Activities, Sleep Hours, Sample Question Papers Practiced이다. test.csv는 3000행이며 목표변수 없이 추론에 사용된다.

전처리는 숫자형 변수 표준화와 범주형 변수 원-핫 인코딩으로 구성했다. 전처리와 모델을 scikit-learn Pipeline으로 묶어 model.pkl에 저장했기 때문에 연구자 2의 추론 환경에서도 동일한 전처리를 재현할 수 있다.

항목	결과
최종 모델	Ridge(alpha=1.0)
검증 방식	train.csv의 20%를 validation set으로 분리
평가지표	RMSE
검증 RMSE	2.0105
산출물	model.pkl, metrics.json, test.csv, result.csv

5. 파일 전달 및 버전 통일 전략

두 컨테이너는 docker-compose에서 같은 ./shared:/shared 바인드 마운트를 사용한다. 연구자 1 컨테이너가 생성한 model.pkl과 test.csv는 shared 디렉터리에 남고, 연구자 2 컨테이너는 해당 파일만 사용해 추론을 수행한다. 이 방식은 연구자 2가 사전에 데이터나 모델 파일을 직접 보유하지 않는다는 시나리오 조건을 만족한다.

두 연구자 컨테이너는 Python 3.11 기반 이미지를 사용한다. 주요 패키지는 numpy==1.26.4, pandas==2.2.3, scikit-learn==1.5.2, joblib==1.4.2로 고정했다. 특히 scikit-learn 버전을 고정하여 model.pkl 저장 및 로드 시 버전 불일치 문제를 줄였다.

6. 실행 검증 결과

로컬 pytest 3개가 통과했고, docker compose build 후 연구자 1 컨테이너와 연구자 2 컨테이너를 각각 실행해 result.csv 3000행 생성을 확인했다.