

미션 16 요약 보고서

1. 미션 목표

이번 미션에서는 MNIST 숫자 분류 모델을 학습한 뒤, 같은 모델을 세 가지 형식으로 저장하고 다시 추론 가능한지 검증했다.

? 기본 PyTorch 저장 형식: .pth

? 양자화된 PyTorch 저장 형식: .pth

? ONNX 저장 형식: .onnx

모델은 28x28 MNIST 이미지를 입력받아 0부터 9까지의 숫자 label을 예측하는 MLP 구조로 구성했다. 이번 과제의 핵심은 모델 성능 경쟁이 아니라 모델 저장, 변환, 재로드, 추론 검증이므로 양자화와 ONNX 변환이 안정적인 Linear 계층 중심 모델을 선택했다.

2. 모델 저장 결과

모델 타입	파일명	용량	테스트 정확도
기본 PyTorch	mission_16_mnist_mlp.pth	2095.63 KB	0.9762
양자화 PyTorch	mission_16_mnist_mlp_quantized.pth	530.24 KB	0.9761
ONNX	mission_16_mnist_mlp.onnx	2094.22 KB	0.9762

양자화 모델은 기본 PyTorch 모델보다 파일 크기가 크게 줄었고, 테스트 정확도는 거의 동일하게 유지되었다.

보고서 첨부 이미지:

? report-assets/mission16_model_size_comparison.png

3. 추론 검증 결과

inference.ipynb에서는 학습을 다시 수행하지 않고 저장된 모델 파일만 불러와 추론을 진행했다. 세 모델 모두 MNIST 테스트 데이터에서 정상적으로 추론되었다.

모델	테스트 정확도
기본 .pth	0.9762
양자화 .pth	0.9761
.onnx	0.9762

샘플 12개 이미지에 대해 세 모델의 예측 label을 비교했으며, 모든 샘플에서 세 모델의 예측이 일치했다.

보고서 첨부 이미지:

? report-assets/mission16_inference_sample_predictions.png

4. 양자화 정리

양자화는 모델 내부의 가중치 값을 더 작은 표현 방식으로 바꾸어 모델 용량을 줄이는 과정이다. 이번 실습에서는 MLP의 Linear 계층에 동적 양자화를 적용했다.

실험 결과 기본 모델은 약 2095.63 KB, 양자화 모델은 약 530.24 KB로 감소했다. 정확도는 0.9762에서 0.9761로 거의 변하지 않았다. 따라서 이번 모델에서는 양자화를 통해 용량을 줄이면서도 추론 성능을 대부분 유지할 수 있었다.

5. 디버깅 및 오류 해결 과정

상황	원인	해결
onnx, onnxruntime import 실패	패키지가 설치되어 있지 않았음	pip install onnx onnxruntime으로 설치 후 버전 확인
ONNX 모델 입력 확인 필요	ONNX Runtime은 정확한 입력 이름과 shape가 필요함	ONNX 그래프를 확인해 입력 이름 input, 입력 shape [1, 1, 28, 28] 확인
양자화 모델 로드 방식 확인 필요	양자화 모델은 기본 모델과 모듈 구조가 달라질 수 있음	같은 MLP 구조에 동적 양자화를 먼저 적용한 뒤 저장된 state dict를 로드
심화 JavaScript 출력 줄바꿈 문제	문자열 조합에서 줄바꿈 문자를 잘못 사용함	\\n 문자열이 아니라 실제 줄바꿈 문자로 수정

6. 심화 미션 결과

심화 미션에서는 제공된 mnist_cnn.onnx 모델을 Python이 아닌 JavaScript/Node.js 환경에서 실행했다. onnxruntime-node와 pngjs를 사용해 28x28 흑백 PNG 이미지를 읽고, MNIST 평균과 표준편차로 정규화한 뒤 ONNX Runtime에 입력했다.

예측 결과는 다음과 같다.

이미지	예측 label	confidence
image1.png	8	1.0000
image2.png	3	1.0000
image3.png	2	1.0000

심화 결과 파일:

? mission-result/advanced-js/src/infer.js

? mission-result/advanced-js/README.md

? mission-result/advanced-js/screenshots/advanced_inference_output.png